

# 第八章 矩阵特征值与特征向量的计算

中国科学技术大学 数学学院

[chenxjin@ustc.edu.cn](mailto:chenxjin@ustc.edu.cn)

在线性代数中，对给定的 $n$ 阶方阵  $A$ ，若存在一个(复)数  $\lambda$  及一个 $n$ 维非零向量  $v$  满足

$$Av = \lambda v,$$

则称  $\lambda$  为  $A$  的特征值， $v$  为属于特征值  $\lambda$  的特征向量.

在线性代数中, 对给定的 $n$ 阶方阵 $A$ , 若存在一个(复)数 $\lambda$ 及一个 $n$ 维非零向量 $v$ 满足

$$Av = \lambda v,$$

则称 $\lambda$ 为 $A$ 的特征值,  $v$ 为属于特征值 $\lambda$ 的特征向量. 显然:

$$\lambda \text{ 为 } A \text{ 的特征值} \iff \lambda \text{ 满足其特征多项式 } |\lambda I_n - A| = 0$$

但是, 一般高次多项式(非线性方程)的求根通常也很困难, 实际计算中很难通过特征多项式的定义来计算矩阵的特征值。

在线性代数中, 对给定的 $n$ 阶方阵 $A$ , 若存在一个(复)数 $\lambda$ 及一个 $n$ 维非零向量 $v$ 满足

$$Av = \lambda v,$$

则称 $\lambda$ 为 $A$ 的特征值,  $v$ 为属于特征值 $\lambda$ 的特征向量. 显然:

$$\lambda \text{ 为 } A \text{ 的特征值} \iff \lambda \text{ 满足其特征多项式 } |\lambda I_n - A| = 0$$

但是, 一般高次多项式(非线性方程)的求根通常也很困难, 实际计算中很难通过特征多项式的定义来计算矩阵的特征值。

比如, 在用迭代法解线性代数方程组时, 其收敛性就与其迭代矩阵 $G$ 的谱半径 $\rho(G)$ 密切相关, 即要求 $\rho(G) < 1$ ; 而求一个矩阵的谱半径往往需要计算其特征值。

在线性代数中, 对给定的 $n$ 阶方阵 $A$ , 若存在一个(复)数 $\lambda$ 及一个 $n$ 维非零向量 $v$ 满足

$$Av = \lambda v,$$

则称 $\lambda$ 为 $A$ 的特征值,  $v$ 为属于特征值 $\lambda$ 的特征向量. 显然:

$$\lambda \text{ 为 } A \text{ 的特征值} \iff \lambda \text{ 满足其特征多项式 } |\lambda I_n - A| = 0$$

但是, 一般高次多项式(非线性方程)的求根通常也很困难, 实际计算中很难通过特征多项式的定义来计算矩阵的特征值。

比如, 在用迭代法解线性代数方程组时, 其收敛性就与其迭代矩阵 $G$ 的谱半径 $\rho(G)$ 密切相关, 即要求 $\rho(G) < 1$ ; 而求一个矩阵的谱半径往往需要计算其特征值。

本章将介绍一些简单有效的计算矩阵特征值和特征向量的数值方法。

矩阵的按模最大特征值往往具有特殊的重要性，如矩阵的谱半径. 幂法(power method)就是一种最经典的求矩阵按模最大特征值与相应的特征向量的方法. 模最大特征值求出后，其他模较小特征值可以由Wielandt压缩法和幂法依次再求.

矩阵的按模最大特征值往往具有特殊的重要性，如矩阵的谱半径。幂法(power method)就是一种最经典的求矩阵按模最大特征值与相应的特征向量的方法。模最大特征值求出后，其他模较小特征值可以由Wielandt压缩法和幂法依次再求。

幂法要求  $A$  有  $n$  个线性无关的特征向量，或者说能相似到对角阵。比如，实对称矩阵或具有互不相同的特征值的矩阵就具有这种性质。设  $A$  的特征值和特征向量如下：

$$\begin{array}{ll} \text{特征值:} & |\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n| \\ \text{特征向量:} & v_1 \quad v_2 \quad \cdots \quad v_n \end{array}$$

# 幂法



## 幂法

设 $A$ 的 $n$ 个线性无关的特征向量为 $\{v_i\}_{i=1}^n$ . 任取初始向量 $x^{(0)}$ , 设

$$x^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n$$

## 幂法

设 $A$ 的 $n$ 个线性无关的特征向量为 $\{v_i\}_{i=1}^n$ . 任取初始向量 $x^{(0)}$ , 设

$$x^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n$$

按幂法迭代格式  $x^{(k)} = Ax^{(k-1)}$

## 幂法

设 $A$ 的 $n$ 个线性无关的特征向量为 $\{v_i\}_{i=1}^n$ . 任取初始向量 $x^{(0)}$ , 设

$$x^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n$$

按幂法迭代格式  $x^{(k)} = Ax^{(k-1)} \Rightarrow x^{(k)} = A^k x^{(0)}$ ,  
得迭代序列  $\{x^{(k)}\}$

$$\begin{aligned} x^{(k)} &= A^k (\alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n) \\ &= \alpha_1 A^k v_1 + \alpha_2 A^k v_2 + \cdots + \alpha_n A^k v_n \\ &= \alpha_1 \lambda_1^k v_1 + \alpha_2 \lambda_2^k v_2 + \cdots + \alpha_n \lambda_n^k v_n \end{aligned}$$

## 幂法

设 $A$ 的 $n$ 个线性无关的特征向量为 $\{v_i\}_{i=1}^n$ . 任取初始向量 $x^{(0)}$ , 设

$$x^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n$$

按幂法迭代格式  $x^{(k)} = Ax^{(k-1)} \Rightarrow x^{(k)} = A^k x^{(0)}$ ,  
得迭代序列  $\{x^{(k)}\}$

$$\begin{aligned} x^{(k)} &= A^k (\alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n) \\ &= \alpha_1 A^k v_1 + \alpha_2 A^k v_2 + \cdots + \alpha_n A^k v_n \\ &= \alpha_1 \lambda_1^k v_1 + \alpha_2 \lambda_2^k v_2 + \cdots + \alpha_n \lambda_n^k v_n \end{aligned}$$

$x^{(k)}$ 的变化趋势与特征值的分布有关, 幂法根据 $x^{(k)}$ 的变化趋势计算矩阵按模最大的特征值与特征向量.

下面讨论两种比较最简单的情况.

下面讨论两种比较最简单的情况.

① 按模最大的特征值只有一个(即为单实根),  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ .

下面讨论两种比较最简单的情况.

① 按模最大的特征值只有一个(即为单实根),  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ . 则:

$$\begin{aligned}x^{(k)} &= \alpha_1 \lambda_1^k v_1 + \alpha_2 \lambda_2^k v_2 + \cdots + \alpha_n \lambda_n^k v_n \\&= \lambda_1^k \left[ \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right]\end{aligned}$$

下面讨论两种比较最简单的情况.

① 按模最大的特征值只有一个(即为单实根),  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ . 则:

$$\begin{aligned}x^{(k)} &= \alpha_1 \lambda_1^k v_1 + \alpha_2 \lambda_2^k v_2 + \cdots + \alpha_n \lambda_n^k v_n \\&= \lambda_1^k \left[ \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right]\end{aligned}$$

设  $\alpha_1 \neq 0$ . 由于  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1 (i \geq 2)$ , 对充分大的  $k$  有  $\left| \left( \frac{\lambda_i}{\lambda_1} \right)^k \right| \ll 1$ , 故

$$\begin{cases} x^{(k)} \approx \lambda_1^k \alpha_1 v_1 \\ x^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 v_1 = \lambda_1 x^{(k)} \end{cases}$$

故  $\lambda_1 \approx \frac{x_i^{(k+1)}}{x_i^{(k)}} (1 \leq i \leq n)$ , 相应的特征向量近似为  $x^{(k)}$ .



下面讨论两种比较最简单的情况.

① 按模最大的特征值只有一个(即为单实根),  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ . 则:

$$\begin{aligned}x^{(k)} &= \alpha_1 \lambda_1^k v_1 + \alpha_2 \lambda_2^k v_2 + \cdots + \alpha_n \lambda_n^k v_n \\&= \lambda_1^k \left[ \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right]\end{aligned}$$

设  $\alpha_1 \neq 0$ . 由于  $\left| \frac{\lambda_i}{\lambda_1} \right| < 1 (i \geq 2)$ , 对充分大的  $k$  有  $\left| \left( \frac{\lambda_i}{\lambda_1} \right)^k \right| \ll 1$ , 故

$$\begin{cases} x^{(k)} \approx \lambda_1^k \alpha_1 v_1 \\ x^{(k+1)} \approx \lambda_1^{k+1} \alpha_1 v_1 = \lambda_1 x^{(k)} \end{cases}$$

故  $\lambda_1 \approx \frac{x_i^{(k+1)}}{x_i^{(k)}} (1 \leq i \leq n)$ , 相应的特征向量近似为  $x^{(k)}$ .

注:  $\frac{x_i^{(k+1)}}{x_i^{(k)}}$  收敛于  $\lambda_1$  的速度取决于  $\left| \frac{\lambda_2}{\lambda_1} \right|$  的大小.

② 按模最大的实特征值有两个，且互为相反数.

② 按模最大的实特征值有两个，且互为相反数. 即

$|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots |\lambda_n|$ ,  $\lambda_1 = -\lambda_2 > 0$ . 由

$$x^{(k)} = \lambda_1^k \left[ \alpha_1 v_1 + (-1)^k \alpha_2 v_2 + \alpha_3 \left( \frac{\lambda_3}{\lambda_1} \right)^k v_3 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right]$$

② 按模最大的实特征值有两个，且互为相反数。即

$$|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots |\lambda_n|, \quad \lambda_1 = -\lambda_2 > 0. \text{ 由}$$

$$x^{(k)} = \lambda_1^k \left[ \alpha_1 v_1 + (-1)^k \alpha_2 v_2 + \alpha_3 \left( \frac{\lambda_3}{\lambda_1} \right)^k v_3 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right]$$

当 $k$ 充分大时有：（不妨设 $\alpha_1 \neq 0 \neq \alpha_2$ ）

$$x^{(k)} \approx \lambda_1^k \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 \right)$$

$x^{(k)}$ 与 $x^{(k+2)}$ 几乎相差一个常数因子 $\lambda_1^2$ 。故此时模最大特征值为：

$$\lambda_1 = \sqrt{x_i^{(k+2)} / x_i^{(k)}}$$

又由 (利用  $x^{(k+2)} \approx \lambda_1^2 x^{(k)}$ )

$$\begin{aligned} A(x^{(k+1)} + \lambda_1 x^{(k)}) &= x^{(k+2)} + \lambda_1 x^{(k+1)} \\ &\approx \lambda_1 (x^{(k+1)} + \lambda_1 x^{(k)}) \end{aligned}$$

$$\begin{aligned} A(x^{(k+1)} - \lambda_1 x^{(k)}) &= x^{(k+2)} - \lambda_1 x^{(k+1)} \\ &\approx -\lambda_1 (x^{(k+1)} - \lambda_1 x^{(k)}) \end{aligned}$$

又由 (利用  $x^{(k+2)} \approx \lambda_1^2 x^{(k)}$ )

$$\begin{aligned} A(x^{(k+1)} + \lambda_1 x^{(k)}) &= x^{(k+2)} + \lambda_1 x^{(k+1)} \\ &\approx \lambda_1 (x^{(k+1)} + \lambda_1 x^{(k)}) \end{aligned}$$

$$\begin{aligned} A(x^{(k+1)} - \lambda_1 x^{(k)}) &= x^{(k+2)} - \lambda_1 x^{(k+1)} \\ &\approx -\lambda_1 (x^{(k+1)} - \lambda_1 x^{(k)}) \end{aligned}$$

知, 与  $\lambda_1, \lambda_2 = -\lambda_1$  对应的特征向量分别为

$$\begin{aligned} v_1 &\approx x^{(k+1)} + \lambda_1 x^{(k)} \\ v_2 &\approx x^{(k+1)} - \lambda_1 x^{(k)} \end{aligned}$$

## 算法描述

向量序列还有很多更复杂的情况，可参考有关书籍或选用其他方法. 本章只讨论幂法计算的两种最简单和基本情况. 具体算法描述如下：

## 算法描述

向量序列还有很多更复杂的情况，可参考有关书籍或选用其他方法. 本章只讨论幂法计算的两种最简单和基本情况. 具体算法描述如下：

1. 选取初值  $x^{(0)}$ ，构造向量序列  $x^{(k)} = Ax^{(k-1)} = A^k x^{(0)}$ .



## 算法描述

向量序列还有很多更复杂的情况，可参考有关书籍或选用其他方法. 本章只讨论幂法计算的两种最简单和基本情况. 具体算法描述如下：

1. 选取初值  $x^{(0)}$ ，构造向量序列  $x^{(k)} = Ax^{(k-1)} = A^k x^{(0)}$ .
2. 若序列表现为，相邻两个向量各个分量比趋于同一常数，则

$$\begin{cases} \lambda_1 \approx x_i^{(k+1)} / x_i^{(k)} \\ v_1 \approx x^{(k)} \end{cases}$$

## 算法描述

向量序列还有很多更复杂的情况，可参考有关书籍或选用其他方法. 本章只讨论幂法计算的两种最简单和基本情况. 具体算法描述如下：

1. 选取初值  $x^{(0)}$ ，构造向量序列  $x^{(k)} = Ax^{(k-1)} = A^k x^{(0)}$ .
2. 若序列表现为，相邻两个向量各个分量比趋于同一常数，则

$$\begin{cases} \lambda_1 \approx x_i^{(k+1)} / x_i^{(k)} \\ v_1 \approx x^{(k)} \end{cases}$$

3. 若序列表现为，奇偶序列各个分量比分别趋向于常数，则

$$\begin{cases} \lambda_1 \approx \sqrt{x_i^{(k+1)} / x_i^{(k-1)}} \\ v_1 \approx x^{(k+1)} + \lambda_1 x^{(k)} \\ v_2 \approx x^{(k+1)} - \lambda_1 x^{(k)} \end{cases}$$

## 算法描述

向量序列还有很多更复杂的情况，可参考有关书籍或选用其他方法. 本章只讨论幂法计算的两种最简单和基本情况. 具体算法描述如下：

1. 选取初值  $x^{(0)}$ ，构造向量序列  $x^{(k)} = Ax^{(k-1)} = A^k x^{(0)}$ .
2. 若序列表现为，相邻两个向量各个分量比趋于同一常数，则

$$\begin{cases} \lambda_1 \approx x_i^{(k+1)} / x_i^{(k)} \\ v_1 \approx x^{(k)} \end{cases}$$

3. 若序列表现为，奇偶序列各个分量比分别趋向于常数，则

$$\begin{cases} \lambda_1 \approx \sqrt{x_i^{(k+1)} / x_i^{(k-1)}} \\ v_1 \approx x^{(k+1)} + \lambda_1 x^{(k)} \\ v_2 \approx x^{(k+1)} - \lambda_1 x^{(k)} \end{cases}$$

4. 若序列表现为其他，退出；需采用其他方法.

例：计算矩阵  $A = \begin{pmatrix} 1/4 & 1/5 \\ 1/5 & 1/6 \end{pmatrix}$  的按模最大的特征值和它的特征向量.

例：计算矩阵  $A = \begin{pmatrix} 1/4 & 1/5 \\ 1/5 & 1/6 \end{pmatrix}$  的按模最大的特征值和它的特征向量.

解：取  $x^{(0)} = (1, 0)^T$ ，计算  $x^{(k)} = Ax^{(k-1)}$ ，结果如下

$k$	$x_1^{(k)}$	$x_2^{(k)}$	$x_1^{(k)} / x_1^{(k-1)}$	$x_2^{(k)} / x_2^{(k-1)}$
0	1	0		
1	0.25	0.2	0.25	—
2	0.10250	0.083333	0.41	0.41665
3	0.042292	0.034389	0.41260	0.41267
4	0.017451	0.014190	0.41263	0.41263

例：计算矩阵  $A = \begin{pmatrix} 1/4 & 1/5 \\ 1/5 & 1/6 \end{pmatrix}$  的按模最大的特征值和它的特征向量.

解：取  $x^{(0)} = (1, 0)^T$ ，计算  $x^{(k)} = Ax^{(k-1)}$ ，结果如下

$k$	$x_1^{(k)}$	$x_2^{(k)}$	$x_1^{(k)} / x_1^{(k-1)}$	$x_2^{(k)} / x_2^{(k-1)}$
0	1	0		
1	0.25	0.2	0.25	—
2	0.10250	0.083333	0.41	0.41665
3	0.042292	0.034389	0.41260	0.41267
4	0.017451	0.014190	0.41263	0.41263

由表知  $A$  的模最大特征值只有一个，且可取  $\lambda_1 \approx 0.41263$ ，对应特征向量为  $v_1 \approx x^{(4)} = (0.017451, 0.014190)^T$ .

# 幂法的规范运算

为什么要进行规范运算？

# 幂法的规范运算

为什么要进行规范运算？前述算法有致命漏洞(BUG)！



## 幂法的规范运算

为什么要进行规范运算？前述算法有致命漏洞(BUG)！

在幂法中，构造的序列为(这里假设模最大特征值唯一， $\alpha_1 \neq 0$ )

$$x^{(k)} = \lambda_1^k \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)$$

## 幂法的规范运算

为什么要进行规范运算？前述算法有致命漏洞(BUG)！

在幂法中，构造的序列为(这里假设模最大特征值唯一， $\alpha_1 \neq 0$ )

$$x^{(k)} = \lambda_1^k \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)$$

可以看出，当 $k \rightarrow \infty$ 时， $x_i^{(k)} \rightarrow \begin{cases} 0, & |\lambda_1| < 1 \\ \infty, & |\lambda_1| > 1 \end{cases}$

## 幂法的规范运算

为什么要进行规范运算？前述算法有致命漏洞(BUG)！

在幂法中，构造的序列为(这里假设模最大特征值唯一， $\alpha_1 \neq 0$ )

$$x^{(k)} = \lambda_1^k \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)$$

可以看出，当 $k \rightarrow \infty$ 时， $x_i^{(k)} \rightarrow \begin{cases} 0, & |\lambda_1| < 1 \\ \infty, & |\lambda_1| > 1 \end{cases}$

因此，若序列收敛较慢的话，很可能造成计算的溢出或归0. 为此，引入**幂法的规范化**.

## 幂法的规范运算

将迭代格式  $x^{(k+1)} = Ax^{(k)}$  改为 
$$\begin{cases} y^{(0)} = x^{(0)} \neq 0 \\ x^{(k+1)} = Ay^{(k)} \\ y^{(k+1)} = \frac{x^{(k+1)}}{\|x^{(k+1)}\|_\infty} \end{cases},$$

通过观察  $\{y^{(k)}\}$  的变化规律来确定  $A$  的模最大特征值和相应的特征向量，称为幂法的规范化。

## 幂法的规范运算

将迭代格式  $x^{(k+1)} = Ax^{(k)}$  改为 
$$\begin{cases} y^{(0)} = x^{(0)} \neq 0 \\ x^{(k+1)} = Ay^{(k)} \\ y^{(k+1)} = \frac{x^{(k+1)}}{\|x^{(k+1)}\|_\infty} \end{cases},$$

通过观察  $\{y^{(k)}\}$  的变化规律来确定  $A$  的模最大特征值和相应的特征向量，称为**幂法的规范化**。

由迭代格式有

$$\begin{cases} y^{(k)} = \frac{Ay^{(k-1)}}{\|x^{(k)}\|_\infty} = \cdots = \frac{A^k y^{(0)}}{\|x^{(k)}\|_\infty \cdots \|x^{(1)}\|_\infty} \\ \|y^{(k)}\|_\infty = 1 \end{cases}$$

$$\Rightarrow y^{(k)} = \frac{A^k y^{(0)}}{\|A^k y^{(0)}\|_\infty}$$

设  $x^{(0)} = y^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n$  (不妨设  $\alpha_1 \neq 0$ ), 则:

$$y^{(k)} = \frac{\lambda_1^k \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)}{|\lambda_1^k| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty}$$

设  $x^{(0)} = y^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \cdots + \alpha_n v_n$  (不妨设  $\alpha_1 \neq 0$ ), 则:

$$y^{(k)} = \frac{\lambda_1^k \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)}{|\lambda_1|^k \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty}$$

① 若  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$  (即为单实根), 则:

$$y^{(k)} \rightarrow \begin{cases} (-1)^k \frac{\alpha_1}{|\alpha_1|} \frac{v_1}{\|v_1\|_\infty}, & \lambda_1 < 0 \\ \frac{\alpha_1}{|\alpha_1|} \frac{v_1}{\|v_1\|_\infty}, & \lambda_1 > 0 \end{cases}$$

当序列  $\{y^{(k)}\}$  有极限或奇偶项分别有符号相反的极限时, 为此种情况。

$$\begin{aligned}
 x^{(k+1)} &= Ay^{(k)} = \frac{A^{k+1}y^{(0)}}{\|A^k y^{(0)}\|_\infty} \\
 &= \frac{\lambda_1^{k+1} \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k+1} v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k+1} v_n \right)}{\left| \lambda_1^k \right| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty} \\
 &\Rightarrow \|x^{(k+1)}\|_\infty \approx \frac{\left| \lambda_1^{k+1} \right| \cdot \|\alpha_1 v_1\|_\infty}{\left| \lambda_1^k \right| \cdot \|\alpha_1 v_1\|_\infty} \approx |\lambda_1|
 \end{aligned}$$



$$\begin{aligned}
 x^{(k+1)} &= Ay^{(k)} = \frac{A^{k+1}y^{(0)}}{\|A^k y^{(0)}\|_\infty} \\
 &= \frac{\lambda_1^{k+1} \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k+1} v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k+1} v_n \right)}{\left| \lambda_1^k \right| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty} \\
 &\Rightarrow \|x^{(k+1)}\|_\infty \approx \frac{\left| \lambda_1^{k+1} \right| \cdot \|\alpha_1 v_1\|_\infty}{\left| \lambda_1^k \right| \cdot \|\alpha_1 v_1\|_\infty} \approx |\lambda_1|
 \end{aligned}$$

- $\{y^{(k)}\}$  收敛时,

$$\begin{aligned}
x^{(k+1)} &= Ay^{(k)} = \frac{A^{k+1}y^{(0)}}{\|A^k y^{(0)}\|_\infty} \\
&= \frac{\lambda_1^{k+1} \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k+1} v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k+1} v_n \right)}{\left| \lambda_1^k \right| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty} \\
&\Rightarrow \|x^{(k+1)}\|_\infty \approx \frac{\left| \lambda_1^{k+1} \right| \cdot \|\alpha_1 v_1\|_\infty}{\left| \lambda_1^k \right| \cdot \|\alpha_1 v_1\|_\infty} \approx |\lambda_1|
\end{aligned}$$

- $\{y^{(k)}\}$  收敛时, 则有  $\lambda_1 > 0$ , 且  $\begin{cases} \lambda_1 \approx \|x^{(k+1)}\|_\infty \\ v_1 \approx y^{(k)} \end{cases}$
- $\{y^{(2k)}\}, \{y^{(2k-1)}\}$  分别收敛到互为反号的两个向量时,

$$\begin{aligned}
 x^{(k+1)} &= Ay^{(k)} = \frac{A^{k+1}y^{(0)}}{\|A^k y^{(0)}\|_\infty} \\
 &= \frac{\lambda_1^{k+1} \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k+1} v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k+1} v_n \right)}{\left| \lambda_1^k \right| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty} \\
 &\Rightarrow \|x^{(k+1)}\|_\infty \approx \frac{\left| \lambda_1^{k+1} \right| \cdot \|\alpha_1 v_1\|_\infty}{\left| \lambda_1^k \right| \cdot \|\alpha_1 v_1\|_\infty} \approx |\lambda_1|
 \end{aligned}$$

- $\{y^{(k)}\}$  收敛时, 则有  $\lambda_1 > 0$ , 且  $\begin{cases} \lambda_1 \approx \|x^{(k+1)}\|_\infty \\ v_1 \approx y^{(k)} \end{cases}$
- $\{y^{(2k)}\}, \{y^{(2k-1)}\}$  分别收敛到互为反号的两个向量时, 则有  $\lambda_1 < 0$ , 且  $\begin{cases} \lambda_1 \approx -\|x^{(k+1)}\|_\infty \\ v_1 \approx y^{(k)} \end{cases}$

② 若  $|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots \geq |\lambda_n|, \lambda_1 = -\lambda_2$  (设  $\alpha_1 \neq 0 \neq \alpha_2$ )

② 若  $|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots \geq |\lambda_n|$ ,  $\lambda_1 = -\lambda_2$  (设  $\alpha_1 \neq 0 \neq \alpha_2$ )

$$y^{(k)} = \frac{\lambda_1^k \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)}{|\lambda_1^k| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty}$$

则  $y^{(2k)}, y^{(2k-1)}$  分别收敛到两个向量且这两个向量之间没有反号关系.

② 若  $|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots \geq |\lambda_n|$ ,  $\lambda_1 = -\lambda_2$  (设  $\alpha_1 \neq 0 \neq \alpha_2$ )

$$y^{(k)} = \frac{\lambda_1^k \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)}{|\lambda_1^k| \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty}$$

则  $y^{(2k)}, y^{(2k-1)}$  分别收敛到两个向量且这两个向量之间没有反号关系.

计算  $\begin{cases} \tilde{x}^{(k+1)} = Ay^{(k)} \\ \tilde{x}^{(k+2)} = A\tilde{x}^{(k+1)} \end{cases}$


$$\tilde{x}^{(k+2)} \approx \lambda_1^2 y^{(k)}$$

② 若  $|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots \geq |\lambda_n|$ ,  $\lambda_1 = -\lambda_2$  (设  $\alpha_1 \neq 0 \neq \alpha_2$ )

$$y^{(k)} = \frac{\lambda_1^k \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right)}{|\lambda_1|^k \cdot \left\| \left( \alpha_1 v_1 + \alpha_2 (-1)^k v_2 + \cdots + \alpha_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \right\|_\infty}$$

则  $y^{(2k)}, y^{(2k-1)}$  分别收敛到两个向量且这两个向量之间没有反号关系.

计算  $\begin{cases} \tilde{x}^{(k+1)} = Ay^{(k)} \\ \tilde{x}^{(k+2)} = A\tilde{x}^{(k+1)} \end{cases} \Rightarrow \begin{cases} \lambda_1 \approx \sqrt{\tilde{x}_i^{(k+2)} / y_i^{(k)}} \\ v_1 \approx \tilde{x}^{(k+2)} + \lambda_1 \tilde{x}^{(k+1)} \\ v_2 \approx \tilde{x}^{(k+2)} - \lambda_1 \tilde{x}^{(k+1)} \end{cases}$



# 规范化幂法的算法描述



## 规范化幂法的算法描述

1. 给出初值, 计算序列 $\{y^{(k)}\}$ .
2. 若序列收敛, 则 $\lambda_1 \approx \|x^{(k+1)}\|_\infty$ ,  $v_1 \approx y^{(k)}$ .
3. 若序列的奇偶序列分别收敛于反号的两个向量, 则 $\lambda_1 \approx -\|x^{(k+1)}\|_\infty$ ,  $v_1 \approx y^{(k)}$ .
4. 若序列的奇偶序列分别收敛, 但不收敛于符号相反的向量, 则
$$\begin{cases} \lambda_1 \approx \sqrt{\tilde{x}_i^{(k+2)} / y_i^{(k)}} \\ v_1 \approx \tilde{x}^{(k+2)} + \lambda_1 \tilde{x}^{(k+1)} \\ v_2 \approx \tilde{x}^{(k+2)} - \lambda_1 \tilde{x}^{(k+1)} \end{cases}, \text{ 其中 } \begin{cases} \tilde{x}^{(k+1)} = Ay^{(k)} \\ \tilde{x}^{(k+2)} = A\tilde{x}^{(k+1)} \end{cases}$$
5. 其他情况需另行考虑.

## 规范化幂法的算法描述

1. 给出初值, 计算序列  $\{y^{(k)}\}$ .
2. 若序列收敛, 则  $\lambda_1 \approx \|x^{(k+1)}\|_\infty$ ,  $v_1 \approx y^{(k)}$ .
3. 若序列的奇偶序列分别收敛于反号的两个向量, 则  $\lambda_1 \approx -\|x^{(k+1)}\|_\infty$ ,  $v_1 \approx y^{(k)}$ .
4. 若序列的奇偶序列分别收敛, 但不收敛于符号相反的向量, 则
$$\begin{cases} \lambda_1 \approx \sqrt{\tilde{x}_i^{(k+2)} / y_i^{(k)}} \\ v_1 \approx \tilde{x}^{(k+2)} + \lambda_1 \tilde{x}^{(k+1)} \\ v_2 \approx \tilde{x}^{(k+2)} - \lambda_1 \tilde{x}^{(k+1)} \end{cases}, \text{ 其中 } \begin{cases} \tilde{x}^{(k+1)} = Ay^{(k)} \\ \tilde{x}^{(k+2)} = A\tilde{x}^{(k+1)} \end{cases}$$
5. 其他情况需另行考虑. **注:** 算法中的序列产生顺序为

$$\begin{aligned} x^{(0)} \rightarrow y^{(0)} = x^{(0)} \rightarrow x^{(1)} = Ay^{(0)} \rightarrow y^{(1)} &= \frac{x^{(1)}}{\|x^{(1)}\|_\infty} \\ \rightarrow x^{(2)} = Ay^{(1)} \rightarrow y^{(2)} &= \frac{x^{(2)}}{\|x^{(2)}\|_\infty} \rightarrow \dots \end{aligned}$$

## Remark

1. 实用的是规范化的幂法.
2. 规范化的幂法不需考虑模最大特征值是否为重根.
3. 算法的收敛速度主要由  $|\frac{\lambda_2}{\lambda_1}|$  决定, 比值越小收敛越快; 由于  $A - p\mathbb{I}_n$  的所有特征值为  $\{\lambda_i - p\}_{i=1}^n$ , 当算法收敛很慢的时候, 可以尝试计算  $A - p\mathbb{I}_n$  的特征值. (参见课本P170的**原点位移法**)
4. 当  $|\lambda_1| = |\lambda_2| > |\lambda_3| \geq \cdots \geq |\lambda_n|$  且  $\lambda_1, \lambda_2$  共轭时, 也可求出  $\lambda_1, \lambda_2$  和它们的特征向量.
5. 若没有其它更多关于模最大特征值的信息, 只能试着做, 由  $y^{(k)}$  的规律判断属于哪种情况, 有可能失败, 需另行处理.

# 反幂法

# 反幂法

用途：计算 $A$ 的模最小特征值与相应的特征向量.

# 反幂法

用途：计算A的模最小特征值与相应的特征向量.

由 $Av = \lambda v \implies A^{-1}v = \frac{1}{\lambda}v$ 知,  $A$ 和 $A^{-1}$ 的特征值互为倒数. 于是对 $A^{-1}$ 使用幂法求其模最大特征值 $\mu$ , 则 $\frac{1}{\mu}$ 即为A的模最小特征值.

# 反幂法

用途：计算A的模最小特征值与相应的特征向量.

由 $Av = \lambda v \implies A^{-1}v = \frac{1}{\lambda}v$ 知,  $A$ 和 $A^{-1}$ 的特征值互为倒数. 于是对 $A^{-1}$ 使用幂法求其模最大特征值 $\mu$ , 则 $\frac{1}{\mu}$ 即为A的模最小特征值.

规范化的反幂法迭代格式为:

$$\begin{cases} y^{(0)} = x^{(0)} \\ x^{(k+1)} = A^{-1}y^{(k)} \\ y^{(k+1)} = x^{(k+1)} / \|x^{(k+1)}\|_{\infty} \end{cases}$$

## 反幂法

用途：计算A的模最小特征值与相应的特征向量.

由 $Av = \lambda v \implies A^{-1}v = \frac{1}{\lambda}v$ 知,  $A$ 和 $A^{-1}$ 的特征值互为倒数. 于是对 $A^{-1}$ 使用幂法求其模最大特征值 $\mu$ , 则 $\frac{1}{\mu}$ 即为 $A$ 的模最小特征值.

规范化的反幂法迭代格式为:

$$\begin{cases} y^{(0)} = x^{(0)} \\ x^{(k+1)} = A^{-1}y^{(k)} \\ y^{(k+1)} = x^{(k+1)} / \|x^{(k+1)}\|_{\infty} \end{cases}$$

为避免求逆运算, 可利用前面的  $LU$  分解(只需作一次)由

$$Ax^{(k+1)} = LUx^{(k+1)} = y^{(k)} \Rightarrow \text{解出 } x^{(k+1)}$$



# 实对称矩阵的Jacobi方法

问题：求实对称矩阵 $A$ 的所有特征值.

# 实对称矩阵的Jacobi方法

问题：求实对称矩阵 $A$ 的所有特征值.

由线性代数知：若矩阵 $A$ 实对称，则存在正交阵 $Q$ ，使得

$$Q^T A Q = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix}$$

对角线上的元素即为 $A$ 的所有特征值（ $Q$ 为正交阵 $\implies Q^T = Q^{-1}$ ）.

# 实对称矩阵的Jacobi方法

问题：求实对称矩阵 $A$ 的所有特征值.

由线性代数知：若矩阵 $A$ 实对称，则存在正交阵 $Q$ ，使得

$$Q^T A Q = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix}$$

对角线上的元素即为 $A$ 的所有特征值（ $Q$ 为正交阵 $\implies Q^T = Q^{-1}$ ）.

直接找 $Q$ 不大容易. Jacobi方法通过构造一系列Givens正交阵 $Q_1, \dots, Q_m$ 对 $A$ 作正交变换，使得非对角元比重逐次变小，当足够小时，可以近似认为对角元就是 $A$ 的所有特征值.

不妨设  $p < q$ , 则 **Givens矩阵**  $\mathbf{Q}(p, q, \theta)$  具有如下形式: (易知它必是一个正交矩阵)

$$\mathbf{Q}(p, q, \theta) = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & & \cos \theta & \cdots & \sin \theta \\ & & & \vdots & \ddots & \vdots \\ & & & -\sin \theta & \cdots & \cos \theta \\ & & & & & 1 & \\ & & & & & & \ddots & \\ & & & & & & & 1 \end{pmatrix}$$

$p$                        $q$   
 $\downarrow$                        $\downarrow$

即  $\mathbf{Q}_{pq} = \sin \theta, \mathbf{Q}_{qp} = -\sin \theta, \mathbf{Q}_{pp} = \mathbf{Q}_{qq} = \cos \theta$

记  $A = (a_{ij})$ ,  $B = \mathbf{Q}^T(p, q, \theta) A \mathbf{Q}(p, q, \theta) = (b_{ij})$ . 则:

$$\begin{cases} b_{ip} = b_{pi} = a_{pi} \cos \theta - a_{qi} \sin \theta, i \neq p, q \\ b_{iq} = b_{qi} = a_{pi} \sin \theta + a_{qi} \cos \theta, i \neq p, q \\ b_{pp} = a_{pp} \cos^2 \theta + a_{qq} \sin^2 \theta - a_{pq} \sin 2\theta \\ b_{qq} = a_{pp} \sin^2 \theta + a_{qq} \cos^2 \theta + a_{pq} \sin 2\theta \\ b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta \end{cases}$$

记  $A = (a_{ij})$ ,  $B = Q^T(p, q, \theta) A Q(p, q, \theta) = (b_{ij})$ . 则:

$$\begin{cases} b_{ip} = b_{pi} = a_{pi} \cos \theta - a_{qi} \sin \theta, i \neq p, q \\ b_{iq} = b_{qi} = a_{pi} \sin \theta + a_{qi} \cos \theta, i \neq p, q \\ b_{pp} = a_{pp} \cos^2 \theta + a_{qq} \sin^2 \theta - a_{pq} \sin 2\theta \\ b_{qq} = a_{pp} \sin^2 \theta + a_{qq} \cos^2 \theta + a_{pq} \sin 2\theta \\ b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta \end{cases}$$

选取  $\theta$  满足:

$$b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta = 0, \text{ 即 } \cot 2\theta = \frac{a_{qq} - a_{pp}}{2a_{pq}} \triangleq s$$

记  $A = (a_{ij})$ ,  $B = Q^T(p, q, \theta) A Q(p, q, \theta) = (b_{ij})$ . 则:

$$\begin{cases} b_{ip} = b_{pi} = a_{pi} \cos \theta - a_{qi} \sin \theta, i \neq p, q \\ b_{iq} = b_{qi} = a_{pi} \sin \theta + a_{qi} \cos \theta, i \neq p, q \\ b_{pp} = a_{pp} \cos^2 \theta + a_{qq} \sin^2 \theta - a_{pq} \sin 2\theta \\ b_{qq} = a_{pp} \sin^2 \theta + a_{qq} \cos^2 \theta + a_{pq} \sin 2\theta \\ b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta \end{cases}$$

选取  $\theta$  满足:

$$b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta = 0, \text{ 即 } \cot 2\theta = \frac{a_{qq} - a_{pp}}{2a_{pq}} \triangleq s$$

令  $t = \tan \theta$  并取三角恒等方程(式)  $t^2 + 2s \cdot t - 1 = 0$  的按模较小根

记  $A = (a_{ij})$ ,  $B = Q^T(p, q, \theta) A Q(p, q, \theta) = (b_{ij})$ . 则:

$$\begin{cases} b_{ip} = b_{pi} = a_{pi} \cos \theta - a_{qi} \sin \theta, i \neq p, q \\ b_{iq} = b_{qi} = a_{pi} \sin \theta + a_{qi} \cos \theta, i \neq p, q \\ b_{pp} = a_{pp} \cos^2 \theta + a_{qq} \sin^2 \theta - a_{pq} \sin 2\theta \\ b_{qq} = a_{pp} \sin^2 \theta + a_{qq} \cos^2 \theta + a_{pq} \sin 2\theta \\ b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta \end{cases}$$

选取  $\theta$  满足:

$$b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta = 0, \text{ 即 } \cot 2\theta = \frac{a_{qq} - a_{pp}}{2a_{pq}} \triangleq s$$

令  $t = \tan \theta$  并取三角恒等方程(式)  $t^2 + 2s \cdot t - 1 = 0$  的按模较小根 (易知,  $t_s = -s \pm \sqrt{s^2 + 1}$ , 特别地, 若  $s = 0$ , 取  $t = 1$ ),



记  $A = (a_{ij})$ ,  $B = \mathbf{Q}^T(p, q, \theta) A \mathbf{Q}(p, q, \theta) = (b_{ij})$ . 则:

$$\begin{cases} b_{ip} = b_{pi} = a_{pi} \cos \theta - a_{qi} \sin \theta, i \neq p, q \\ b_{iq} = b_{qi} = a_{pi} \sin \theta + a_{qi} \cos \theta, i \neq p, q \\ b_{pp} = a_{pp} \cos^2 \theta + a_{qq} \sin^2 \theta - a_{pq} \sin 2\theta \\ b_{qq} = a_{pp} \sin^2 \theta + a_{qq} \cos^2 \theta + a_{pq} \sin 2\theta \\ b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta \end{cases}$$

选取  $\theta$  满足:

$$b_{pq} = b_{qp} = a_{pq} \cos 2\theta + \frac{a_{pp} - a_{qq}}{2} \sin 2\theta = 0, \text{ 即 } \cot 2\theta = \frac{a_{qq} - a_{pp}}{2a_{pq}} \triangleq s$$

令  $t = \tan \theta$  并取三角恒等方程(式)  $t^2 + 2s \cdot t - 1 = 0$  的按模较小根 (易知,  $t_s = -s \pm \sqrt{s^2 + 1}$ , 特别地, 若  $s = 0$ , 取  $t = 1$ ), 可得

$$\begin{cases} \cos \theta = \frac{1}{\sqrt{1+t^2}} \\ \sin \theta = \frac{t}{\sqrt{1+t^2}} \end{cases}, \text{ 以及Givens矩阵 } \mathbf{Q}, \text{ 且有 } b_{pq} = b_{qp} = 0;$$

此时,  $\begin{cases} b_{pp} = a_{pp} - ta_{pq} \\ b_{qq} = a_{qq} + ta_{pq}. \end{cases}$  记  $\sigma_1(A) = \sum_{i \neq j} a_{ij}^2$ ,  $\sigma_2(A) = \sum_{i=1}^n a_{ii}^2$ , 则可

证: (参见, 第3版, 177页)

$$\begin{cases} \sigma_1(B) \equiv \sum_{i \neq j} b_{ij}^2 = \sigma_1(A) - 2a_{pq}^2 \\ \sigma_2(B) \equiv \sum_{i=1}^n b_{ii}^2 = \sigma_2(A) + 2a_{pq}^2 \end{cases}$$

此时,  $\begin{cases} b_{pp} = a_{pp} - ta_{pq} \\ b_{qq} = a_{qq} + ta_{pq} \end{cases}$  记  $\sigma_1(A) = \sum_{i \neq j} a_{ij}^2$ ,  $\sigma_2(A) = \sum_{i=1}^n a_{ii}^2$ , 则可

证: (参见, 第3版, 177页)

$$\begin{cases} \sigma_1(B) \equiv \sum_{i \neq j} b_{ij}^2 = \sigma_1(A) - 2a_{pq}^2 \\ \sigma_2(B) \equiv \sum_{i=1}^n b_{ii}^2 = \sigma_2(A) + 2a_{pq}^2 \end{cases}$$

注: 由  $A$  变到  $B = Q^T A Q$ , 特征值不变, 但对角元所占比重一般会增大 ( $a_{pq} = 0$  时, 比重不变) .

此时,  $\begin{cases} b_{pp} = a_{pp} - ta_{pq} \\ b_{qq} = a_{qq} + ta_{pq} \end{cases}$  记  $\sigma_1(A) = \sum_{i \neq j} a_{ij}^2$ ,  $\sigma_2(A) = \sum_{i=1}^n a_{ii}^2$ , 则可

证: (参见, 第3版, 177页)

$$\begin{cases} \sigma_1(B) \equiv \sum_{i \neq j} b_{ij}^2 = \sigma_1(A) - 2a_{pq}^2 \\ \sigma_2(B) \equiv \sum_{i=1}^n b_{ii}^2 = \sigma_2(A) + 2a_{pq}^2 \end{cases}$$

注: 由  $A$  变到  $B = Q^T A Q$ , 特征值不变, 但对角元所占比重一般会增大 ( $a_{pq} = 0$  时, 比重不变).

记  $A^{(0)} = (a_{ij})$ ,  $A^{(k)}$  为对  $A^{(k-1)}$  进行一次如前的Givens变换后所得矩阵. 则:

此时,  $\begin{cases} b_{pp} = a_{pp} - ta_{pq} \\ b_{qq} = a_{qq} + ta_{pq} \end{cases}$  记  $\sigma_1(A) = \sum_{i \neq j} a_{ij}^2$ ,  $\sigma_2(A) = \sum_{i=1}^n a_{ii}^2$ , 则可

证: (参见, 第3版, 177页)

$$\begin{cases} \sigma_1(B) \equiv \sum_{i \neq j} b_{ij}^2 = \sigma_1(A) - 2a_{pq}^2 \\ \sigma_2(B) \equiv \sum_{i=1}^n b_{ii}^2 = \sigma_2(A) + 2a_{pq}^2 \end{cases}$$

注: 由  $A$  变到  $B = Q^T A Q$ , 特征值不变, 但对角元所占比重一般会增大 ( $a_{pq} = 0$  时, 比重不变).

记  $A^{(0)} = (a_{ij})$ ,  $A^{(k)}$  为对  $A^{(k-1)}$  进行一次如前的Givens变换后所得矩阵. 则:

定理: 若  $A$  实对称, 则  $A^{(k)}$  收敛于  $\text{diag}\{\lambda_1, \dots, \lambda_n\}$ .

此时,  $\begin{cases} b_{pp} = a_{pp} - ta_{pq} \\ b_{qq} = a_{qq} + ta_{pq} \end{cases}$  记  $\sigma_1(A) = \sum_{i \neq j} a_{ij}^2$ ,  $\sigma_2(A) = \sum_{i=1}^n a_{ii}^2$ , 则可

证: (参见, 第3版, 177页)

$$\begin{cases} \sigma_1(B) \equiv \sum_{i \neq j} b_{ij}^2 = \sigma_1(A) - 2a_{pq}^2 \\ \sigma_2(B) \equiv \sum_{i=1}^n b_{ii}^2 = \sigma_2(A) + 2a_{pq}^2 \end{cases}$$

注: 由  $A$  变到  $B = Q^T A Q$ , 特征值不变, 但对角元所占比重一般会增大 ( $a_{pq} = 0$  时, 比重不变).

记  $A^{(0)} = (a_{ij})$ ,  $A^{(k)}$  为对  $A^{(k-1)}$  进行一次如前的Givens变换后所得矩阵. 则:

定理: 若  $A$  实对称, 则  $A^{(k)}$  收敛于  $\text{diag}\{\lambda_1, \dots, \lambda_n\}$ .

注: 为了让  $A^{(k)}$  收敛得更快, 一般选取  $p, q$  ( $p \neq q$ ) 使得对应位置的元素的模最大.

例：用Jacobi方法计算对称阵  $\mathbf{A} = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 5 & 1 \\ 2 & 1 & 6 \end{pmatrix}$  的全部特征值.

例：用Jacobi方法计算对称阵  $\mathbf{A} = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 5 & 1 \\ 2 & 1 & 6 \end{pmatrix}$  的全部特征值.

解：记  $A^{(0)} = A$ ，选取  $p = 1, q = 2$ .  $a_{pq}^{(0)} = a_{12}^{(0)} = 2$ ,



例：用Jacobi方法计算对称阵  $\mathbf{A} = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 5 & 1 \\ 2 & 1 & 6 \end{pmatrix}$  的全部特征值.

解：记  $A^{(0)} = A$ ，选取  $p = 1, q = 2$ .  $a_{pq}^{(0)} = a_{12}^{(0)} = 2$ ，于是有  
 $s = \frac{a_{22}^{(0)} - a_{11}^{(0)}}{2a_{12}^{(0)}} = 0.25$ ， $t$  取为  $t^2 + 2st - 1 = 0$  的按模较小根，  
故  $t = 0.780776$ . 进而得到：

$$\cos \theta = (1 + t^2)^{-\frac{1}{2}} = 0.788206, \sin \theta = t \cos \theta = 0.615412$$

此即为Givens变换矩阵所需元素.

$$\mathbf{Q}_1 = \mathbf{Q}(\mathbf{p}, \mathbf{q}, \theta) = \begin{pmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0.788206 & 0.615412 & 0 \\ -0.615412 & 0.788206 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

故有：

$$\mathbf{A}^{(1)} = \mathbf{Q}_1^T \mathbf{A}^{(0)} \mathbf{Q}_1 = \begin{pmatrix} 2.438448 & 0 & 0.961 \\ 0 & 6.561552 & 2.01903 \\ 0.961 & 2.01903 & 6 \end{pmatrix}$$

$$\mathbf{Q}_1 = \mathbf{Q}(\mathbf{p}, \mathbf{q}, \theta) = \begin{pmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0.788206 & 0.615412 & 0 \\ -0.615412 & 0.788206 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

故有：

$$\mathbf{A}^{(1)} = \mathbf{Q}_1^T \mathbf{A}^{(0)} \mathbf{Q}_1 = \begin{pmatrix} 2.438448 & 0 & 0.961 \\ 0 & 6.561552 & 2.01903 \\ 0.961 & 2.01903 & 6 \end{pmatrix}$$

再选取  $p = 2, q = 3$ ,  $a_{pq}^{(1)} = a_{23}^{(1)} = 2.01903$ , 类似地可得

$$\mathbf{A}^{(2)} = \begin{pmatrix} 2.438448 & 0.631026 & 0.724794 \\ 0.631026 & 8.320386 & 0 \\ 0.724794 & 0 & 4.241166 \end{pmatrix}$$

$$\mathbf{A}^{(3)} = \begin{pmatrix} 2.183185 & 0.595192 & 0 \\ 0.595192 & 8.320386 & 0.209614 \\ 0 & 0.209614 & 4.496424 \end{pmatrix}$$

$$\mathbf{A}^{(4)} = \begin{pmatrix} 2.125995 & 0 & -0.020048 \\ 0 & 8.377576 & 0.208653 \\ -0.020048 & 0.208653 & 4.496424 \end{pmatrix}$$

$$\mathbf{A}^{(5)} = \begin{pmatrix} 2.125995 & -0.001073 & -0.020019 \\ -0.001073 & 8.388761 & 0 \\ -0.020019 & 0 & 4.485239 \end{pmatrix}$$

$$\mathbf{A}^{(6)} = \begin{pmatrix} 2.125825 & 0 & -0.001072 \\ 0 & 8.388761 & 0.000009 \\ -0.001072 & 0.000009 & 4.485401 \end{pmatrix}$$

$$\mathbf{A}^{(7)} = \begin{pmatrix} 2.125825 & 0 & 0 \\ 0 & 8.388761 & 0.000009 \\ 0 & 0.000009 & 4.485401 \end{pmatrix}$$

$$\mathbf{A}^{(6)} = \begin{pmatrix} 2.125825 & 0 & -0.001072 \\ 0 & 8.388761 & 0.000009 \\ -0.001072 & 0.000009 & 4.485401 \end{pmatrix}$$

$$\mathbf{A}^{(7)} = \begin{pmatrix} 2.125825 & 0 & 0 \\ 0 & 8.388761 & 0.000009 \\ 0 & 0.000009 & 4.485401 \end{pmatrix}$$

从而 $A$ 的特征值可取为

$$\lambda_1 \approx 2.125825, \lambda_2 \approx 8.388761, \lambda_3 \approx 4.485401$$

# QR方法简介

## Theorem (QR分解定理)

若  $A$  为  $n$  阶实矩阵，则存在正交阵  $Q$  和上三角阵  $R$  使得  $A = QR$ 。

# QR方法简介

## Theorem (QR分解定理)

若  $A$  为  $n$  阶实矩阵, 则存在正交阵  $Q$  和上三角阵  $R$  使得  $A = QR$ 。

注: 定理中的  $Q, R$  均有构造性算法求出. 建立在QR分解上的QR方法是求矩阵全部特征值的有效方法, 在  $A$  为对称阵时效率至少可与Jacobi 方法相当.



# QR方法简介

## Theorem (QR分解定理)

若  $A$  为  $n$  阶实矩阵, 则存在正交阵  $Q$  和上三角阵  $R$  使得  $A = QR$ 。

注: 定理中的  $Q, R$  均有构造性算法求出. 建立在QR分解上的QR方法是求矩阵全部特征值的有效方法, 在  $A$  为对称阵时效率至少可与Jacobi 方法相当. 基本思路为: 令  $A_1 \triangleq A$ .

作  $A_1$  的QR分解  $A_1 = Q_1 \cdot R_1$ .  $A_2 \triangleq R_1 \cdot Q_1$

→ 作  $A_2$  的QR分解  $A_2 = Q_2 \cdot R_2$ .  $A_3 \triangleq R_2 \cdot Q_2$

→ 作  $A_3$  的QR分解  $A_3 = Q_3 \cdot R_3$ .  $A_4 \triangleq R_3 \cdot Q_3$

→ ...

# QR方法简介

## Theorem (QR分解定理)

若  $A$  为  $n$  阶实矩阵, 则存在正交阵  $Q$  和上三角阵  $R$  使得  $A = QR$ 。

注: 定理中的  $Q, R$  均有构造性算法求出. 建立在QR分解上的QR方法是求矩阵全部特征值的有效方法, 在  $A$  为对称阵时效率至少可与Jacobi 方法相当. 基本思路为: 令  $A_1 \triangleq A$ .

$$\begin{aligned} & \text{作 } A_1 \text{ 的 QR 分解 } A_1 = Q_1 \cdot R_1. \quad A_2 \triangleq R_1 \cdot Q_1 \\ \longrightarrow & \text{作 } A_2 \text{ 的 QR 分解 } A_2 = Q_2 \cdot R_2. \quad A_3 \triangleq R_2 \cdot Q_2 \\ \longrightarrow & \text{作 } A_3 \text{ 的 QR 分解 } A_3 = Q_3 \cdot R_3. \quad A_4 \triangleq R_3 \cdot Q_3 \\ \longrightarrow & \dots \end{aligned}$$

由以上过程构造的矩阵序列  $\{A_k\}$  全部(正交)相似, 且在  $A$  满足一定条件时,  $A_k$  收敛到上三角矩阵

## 矩阵的QR分解

注：矩阵的QR分解算法实际上得到

$$Q^T A = R$$

## 矩阵的QR分解

注：矩阵的QR分解算法实际上得到

$$Q^T A = R \Leftrightarrow A = QR.$$

## 矩阵的QR分解

注：矩阵的QR分解算法实际上得到

$$Q^T A = R \Leftrightarrow A = QR.$$

### Theorem

Let  $x, y \in \mathbb{R}^n$  s.t.  $\|x\|_2 = \|y\|_2$ . Then there exists an orthogonal matrix (正交矩阵)  $U$  of the form  $I - 2vv^T$  s.t.  $Ux = y$ , where  $v = \frac{x-y}{\|x-y\|_2}$ .

## 矩阵的QR分解

注：矩阵的QR分解算法实际上得到

$$Q^T A = R \Leftrightarrow A = QR.$$

### Theorem

Let  $x, y \in \mathbb{R}^n$  s.t.  $\|x\|_2 = \|y\|_2$ . Then there exists an orthogonal matrix (正交矩阵)  $U$  of the form  $I - 2vv^T$  s.t.  $Ux = y$ , where  $v = \frac{x-y}{\|x-y\|_2}$ .

- **Remark:** an orthogonal matrix  $U$  of the form  $I - 2vv^T$  is called a **Householder matrix**. It's easy to see that  $U = U^T$  and  $\det u = -1$ .  $Ux = y$  is a **Householder transformation** (变换) or **mirror mapping** (镜像映射)

在QR分解的第一步, let

$$v_1 = (A_1 - \beta_1 e^{(1)}) / \|A_1 - \beta_1 e^{(1)}\|_2 \quad \text{where}$$

$$A = (A_1, A_2, \dots, A_n), \quad e^{(1)} = (1, 0, \dots, 0)^T,$$

$$\beta_1 = \|A_1\|_2$$

在QR分解的第一步, let

$$v_1 = (A_1 - \beta_1 e^{(1)}) / \|A_1 - \beta_1 e^{(1)}\|_2 \quad \text{where}$$

$$A = (A_1, A_2, \dots, A_n), \quad e^{(1)} = (1, 0, \dots, 0)^T,$$

$$\beta_1 = \|A_1\|_2 \quad \Rightarrow \quad \|A_1\|_2 = \|\beta_1 e^{(1)}\|_2,$$



在QR分解的第一步, let

$$v_1 = (A_1 - \beta_1 e^{(1)}) / \|A_1 - \beta_1 e^{(1)}\|_2 \quad \text{where}$$

$$A = (A_1, A_2, \dots, A_n), \quad e^{(1)} = (1, 0, \dots, 0)^T,$$

$$\beta_1 = \|A_1\|_2 \quad \Rightarrow \quad \|A_1\|_2 = \|\beta_1 e^{(1)}\|_2,$$

By the previous Theorem, (**Householder 变换**)

$$U_1 A_1 \equiv (I - 2v_1 v_1^T) A_1 = \beta_1 e^{(1)}$$

在QR分解的第一步, let

$$v_1 = (A_1 - \beta_1 e^{(1)}) / \|A_1 - \beta_1 e^{(1)}\|_2 \quad \text{where}$$

$$A = (A_1, A_2, \dots, A_n), \quad e^{(1)} = (1, 0, \dots, 0)^T,$$

$$\beta_1 = \|A_1\|_2 \quad \Rightarrow \quad \|A_1\|_2 = \|\beta_1 e^{(1)}\|_2,$$

By the previous Theorem, (**Householder 变换**)

$$U_1 A_1 \equiv (I - 2v_1 v_1^T) A_1 = \beta_1 e^{(1)}$$

Denote

$$U_1 A = \begin{pmatrix} \beta_1 & * \\ \mathbf{0} & B_{(n-1) \times (n-1)} \end{pmatrix}_{n \times n}$$

and  $B_{(n-1) \times (n-1)} = (B_1, B_2, \dots, B_{n-1})$ .

and  $B_{(n-1) \times (n-1)} = (B_1, B_2, \dots, B_{n-1})$ .

Next, construct another orthogonal matrix  $U_2$  s.t.

$$U_2 U_1 A_1 = \beta_1 \mathbf{e}^{(1)}, \quad U_2 U_1 A_2 = (*, \beta_2, 0, \dots, 0)^T$$

and  $B_{(n-1) \times (n-1)} = (B_1, B_2, \dots, B_{n-1})$ .

Next, construct another orthogonal matrix  $U_2$  s.t.

$$U_2 U_1 A_1 = \beta_1 \mathbf{e}^{(1)}, U_2 U_1 A_2 = (*, \beta_2, 0, \dots, 0)^T$$

$$U_2 = \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & I_{(n-1) \times (n-1)} - 2\mathbf{v}_2 \mathbf{v}_2^T \end{pmatrix}_{n \times n}, \quad \text{where}$$

$$\mathbf{v}_2 \in \mathbb{R}^{n-1}, \quad \|\mathbf{v}\|_2 = (B_1 - \beta_2 \bar{\mathbf{e}}^{(1)}) / \|B_1 - \beta_2 \bar{\mathbf{e}}^{(1)}\|_2,$$

$$\text{and } \beta_2 = \|B_1\|_2, \quad \bar{\mathbf{e}}^{(1)} = (1, 0, \dots, 0)^T \in \mathbf{R}^{n-1}.$$

In general, the orthogonal matrix  $Q^T$  is build up step-by-step as

$$Q^T = U_{n-1} U_{n-2} \cdots U_1$$

where

$$U_k = \begin{pmatrix} I_{(k-1) \times (k-1)} & \mathbf{0} \\ \mathbf{0} & I_{(n-k+1) \times (n-k+1)} - 2\mathbf{v}\mathbf{v}^T \end{pmatrix}_{n \times n}$$

with  $\mathbf{v} \in \mathbb{R}^{n-k+1}$  ( $k = 1, \dots, n-1$ ),  $\|\mathbf{v}\|_2 = 1$ .

In general, the orthogonal matrix  $Q^T$  is build up step-by-step as

$$Q^T = U_{n-1} U_{n-2} \cdots U_1$$

where

$$U_k = \begin{pmatrix} I_{(k-1) \times (k-1)} & \mathbf{0} \\ \mathbf{0} & I_{(n-k+1) \times (n-k+1)} - 2\mathbf{v}\mathbf{v}^T \end{pmatrix}_{n \times n}$$

with  $\mathbf{v} \in \mathbb{R}^{n-k+1}$  ( $k = 1, \dots, n-1$ ),  $\|\mathbf{v}\|_2 = 1$ .  
Finally, we have

$$Q^T A \equiv U_{n-1} U_{n-2} \cdots U_1 A = R_{n \times n}$$

In general, the orthogonal matrix  $Q^T$  is build up step-by-step as

$$Q^T = U_{n-1} U_{n-2} \cdots U_1$$

where

$$U_k = \begin{pmatrix} I_{(k-1) \times (k-1)} & \mathbf{0} \\ \mathbf{0} & I_{(n-k+1) \times (n-k+1)} - 2\mathbf{v}\mathbf{v}^T \end{pmatrix}_{n \times n}$$

with  $\mathbf{v} \in \mathbb{R}^{n-k+1}$  ( $k = 1, \dots, n-1$ ),  $\|\mathbf{v}\|_2 = 1$ .  
Finally, we have

$$Q^T A \equiv U_{n-1} U_{n-2} \cdots U_1 A = R_{n \times n} \Leftrightarrow A = QR$$

where



$$R_{n \times n} = \begin{pmatrix} \beta_1 & * & \dots & * & * \\ 0 & \beta_2 & \dots & * & * \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \beta_{n-1} & * \\ 0 & 0 & \dots & 0 & * \end{pmatrix}$$

## Example (See also P182, 例8.9)

Use the Householder transformation to find the QR-factorization of the matrix

$$A = \begin{pmatrix} \mathbf{12} & -51 & 4 \\ 6 & \mathbf{167} & -68 \\ -4 & 24 & -\mathbf{41} \end{pmatrix}$$

Solution. Let

$$x = A_1 = (12, 6, -4)^T, \quad \beta_1 = \|A_1\|_2 = 14,$$

$$y = \beta_1 e_1 = (14, 0, 0)^T, \text{ and}$$

$$v = \frac{x-y}{\|x-y\|} = \frac{1}{2\sqrt{14}}(-2, 6, -4)^T = \frac{1}{\sqrt{14}}(-1, 3, -2)^T.$$

So

$$U_1 = I - 2vv^T = \begin{pmatrix} 6/7 & 3/7 & -2/7 \\ 3/7 & -2/7 & 6/7 \\ -2/7 & 6/7 & 3/7 \end{pmatrix}$$

$$U_1 A = \begin{pmatrix} 14 & 21 & -14 \\ 0 & -49 & -14 \\ 0 & 168 & 77 \end{pmatrix}$$

Similarly, one can construct the 2nd orthogonal matrix

$$U_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & -7/25 & 24/25 \\ 0 & 24/25 & 7/25 \end{pmatrix}$$

and get

Similarly, one can construct the 2nd orthogonal matrix

$$U_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & -7/25 & 24/25 \\ 0 & 24/25 & 7/25 \end{pmatrix}$$

and get

$$U_2 U_1 A = \begin{pmatrix} 14 & 21 & -14 \\ 0 & -175 & -70 \\ 0 & 0 & -35 \end{pmatrix}$$

Similarly, one can construct the 2nd orthogonal matrix

$$U_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & -7/25 & 24/25 \\ 0 & 24/25 & 7/25 \end{pmatrix}$$

and get

$$U_2 U_1 A = \begin{pmatrix} 14 & 21 & -14 \\ 0 & -175 & -70 \\ 0 & 0 & -35 \end{pmatrix} = R \Leftrightarrow$$

$$Q^T A = R \Leftrightarrow A = QR$$